Estructuración y modelado de datos: análisis y proceso ETL sobre las importaciones con destino a Bogotá

Barrios Alfonso Samuel Andres

Molano Castillo Diego Mauricio

Panadero Chavarro Santiago

Rodriguez Vargas Samuel Alejandro

Fundación Universitaria Compensar

Estructuración y Modelado de Datos

Neider Duan Barbosa Castro

14 de septiembre de 2026

SELECCIÓN Y JUSTIFICACIÓN DE LOS DATOS

Dataset seleccionado y entidad que lo publica

El dataset seleccionado es "Importaciones Bogotá", publicado por la Secretaría Distrital de Desarrollo Económico (SDDE) en el portal Datos Abiertos Bogotá (https://datosabiertos.bogota.gov.co/dataset/importaciones-bogota). El conjunto de datos fue consultado el 20 de agosto de 2026.

El conjunto provee el valor y la cantidad de las importaciones con destino a Bogotá, desagregadas por país de origen, partida arancelaria, código CIIU Rev. 4 A.C., nivel tecnológico, uso económico y detalle de uso económico, con información acumulada desde enero de 2025 hasta febrero de 2026. En su versión descargada, el archivo contiene 132.289 registros distribuidos en 17 columnas.

Por qué se seleccionó

Elegimos este conjunto porque combina varias características deseables para un ejercicio de estructuración y modelado de datos: es un dataset real, de origen institucional, de tamaño considerable (más de 130.000 filas), con múltiples variables categóricas jerárquicas (país, partida, capítulo, CIIU) que se prestan naturalmente a un proceso de normalización relacional, y con problemas de calidad genuinos (duplicados, inconsistencias de escritura, ambigüedad conceptual) que permiten aplicar de forma significativa las técnicas de ETL vistas en el curso, en lugar de trabajar con datos ya limpios donde el ejercicio perdería sentido.

Problemática que permite estudiar

El dataset nos permite estudiar cómo se comporta el comercio exterior de la ciudad de Bogotá en términos de origen de las mercancías, su clasificación arancelaria y

económica, y su relevancia tecnológica, además de evidenciar un problema transversal a los datos abiertos gubernamentales en Colombia: la publicación de información desnormalizada, con texto repetido y categorías inconsistentes, que dificulta su explotación analítica directa sin un proceso previo de limpieza y modelado.

Para qué pueden utilizarse estos datos

Los datos pueden utilizarse para:

(a). Caracterizar los principales países proveedores de Bogotá y su evolución mensual.

(b). Identificar los sectores económicos (vía CIIU) y niveles tecnológicos con mayor participación en las importaciones.

(c). Apoyar estudios de política pública distrital sobre dependencia de insumos importados.

(d). Servir de base para un modelo relacional reutilizable por otras entidades o investigadores que requieran consultar esta información de forma estructurada.

Variables relevantes

Las variables más relevantes para el análisis son: Período y mes (temporalidad), código y nombre del país de origen, código y nombre de la partida arancelaria, código de capítulo, código y descripción CIIU Rev. 4 A.C., nivel tecnológico, uso económico y detalle de uso económico (clasificación de la transacción), y las métricas cuantitativas: dólares CIF, dólares FOB, kilogramos netos y cantidad.

Qué información se espera obtener

Esperamos obtener una caracterización confiable de los flujos de importación hacia Bogotá por origen, categoría arancelaria y sector económico, libre de duplicados y

de inconsistencias de categorización, junto con un modelo relacional que permita futuras consultas analíticas (por ejemplo, ranking de países por valor CIF, o participación de cada nivel tecnológico en el total importado) sin arrastrar los problemas de calidad identificados en el archivo original.

Limitaciones de los datos

El dataset presenta varias limitaciones: Cubre un período relativamente corto (enero 2025-febrero 2026), no permite comparaciones interanuales de mediano plazo; algunas columnas categóricas mezclan conceptualmente entidades distintas (países y zonas francas en "país de origen"), existen inconsistencias de escritura en campos de texto libre ("Sin información" y "Sin Información"), y se identificaron valores en cero en las columnas de valor FOB y CIF que resultan atípicos para transacciones de comercio exterior reales, cuyo origen no puede determinarse con certeza únicamente a partir del archivo.

FORMULACIÓN DEL PROYECTO

1. **Título:** Estructuración y modelado relacional de los datos de importaciones con destino a Bogotá mediante un proceso ETL (2025-2026).
2. **Introducción:** El presente proyecto aborda el conjunto de datos "Importaciones Bogotá", publicado por la Secretaría Distrital de Desarrollo Económico en el portal Datos Abiertos Bogotá, con el fin de aplicar un proceso completo de Extracción, Transformación y Carga (ETL) que permita transformar un archivo desnormalizado y con problemas de calidad en una estructura de datos relacional, consistente y consultable. El proyecto combina tres frentes de trabajo:
    - La limpieza y transformación de los datos utilizando Power Query y OpenRefine.
    - El análisis de su consistencia y su contenido.
    - Por último el diseño del modelo relacional, el cual está enfocado en las dependencias funcionales reales observadas en los datos.

3. **Planteamiento del problema:** Los portales de datos abiertos gubernamentales, en cumplimiento de la Ley 1712 de 2014 sobre transparencia y acceso a la información pública, publican grandes volúmenes de información en formatos planos (hojas de cálculo o CSV) que privilegian la interoperabilidad y la publicación rápida, pero no necesariamente la calidad ni la estructura óptima para el análisis (Wang & Strong, 1996). - El dataset "Importaciones Bogotá" es un caso representativo de este fenómeno: en su forma original mezcla en una sola tabla plana información jerárquica (país, partida, capítulo, actividad CIIU) con texto

descriptivo repetido miles de veces, contiene filas duplicadas, valores numéricos en cero que resultan sospechosos dada la definición de las variables (Dirección de Impuestos y Aduanas Nacionales [DIAN], 2024), e inconsistencias de escritura en columnas categóricas clave. Esta desnormalización dificulta su uso directo para análisis confiables y expone al usuario final al riesgo de sacar conclusiones erróneas si trabaja sobre los datos sin depurarlos ni modelarlos adecuadamente. De lo anterior surge la pregunta problema que guía este proyecto: ¿Cómo organizar y corregir los datos de importaciones de Bogotá mediante un proceso ETL, para garantizar su calidad e integridad?

4. **Justificación:** Este proyecto es pertinente porque ilustra, sobre un caso real, la brecha que suele existir entre la publicación de datos abiertos y su aprovechamiento efectivo. Sus principales beneficiarios son, en primer lugar, el propio grupo de trabajo, al aplicar de forma práctica los conceptos de ETL, calidad de datos y modelado relacional vistos en el curso y en un plano más amplio, cualquier analista, investigador o entidad distrital que requiera consultar de forma confiable las importaciones de la ciudad sin tener que repetir el proceso de limpieza. La aplicación de un proceso ETL es pertinente precisamente porque el archivo original no es utilizable de forma directa para análisis serios: contiene duplicados exactos, valores faltantes disfrazados de ceros, y categorías con más de una forma de escritura para un mismo concepto, todo lo cual debe corregirse antes de poder confiar en cualquier resultado derivado de los datos (Kimball & Caserta, 2004).

OBJETIVOS

Objetivo general

Estructurar y modelar los datos del conjunto "Importaciones Bogotá" mediante un proceso ETL, con el fin de obtener una base de datos relacional consistente, íntegra y analíticamente útil para caracterizar las importaciones con destino a la ciudad.

Objetivos específicos

1. Analizar la calidad y consistencia de los datos originales.
2. Extraer, limpiar y transformar los datos mediante Power Query y OpenRefine.
3. Diseñar un modelo relacional que garantice integridad y evite redundancias.
4. Comparar y presentar los resultados obtenidos antes y después del proceso ETL.

MARCO DE REFERENCIA

Datos abiertos y transparencia

En Colombia, la Ley 1712 de 2014 define los datos abiertos como aquellos datos primarios o sin procesar, dispuestos en formatos estándar e interoperables, bajo custodia de entidades públicas, que se ponen a disposición de cualquier ciudadano de forma libre para su reutilización (Congreso de la República de Colombia, 2014). Esta norma es el fundamento legal que explica por qué existe un dataset como "Importaciones Bogotá" disponible públicamente, y por qué su formato prioriza la publicación sobre la estructura analítica óptima (Ministerio de Tecnologías de la Información y las Comunicaciones [MinTIC], s.f.).

Proceso ETL

El proceso de Extracción, Transformación y Carga (ETL, por sus siglas en inglés) es la fase más demandante en tiempo y esfuerzo dentro del desarrollo de cualquier solución de datos, encargada de extraer la información de los sistemas de origen, depurar y estandarizarla, y entregarla en un formato listo para su análisis (Kimball & Caserta, 2004). En este proyecto, la extracción corresponde a la descarga del dataset desde Datos Abiertos Bogotá, la transformación se realiza en dos herramientas complementarias, Power Query (para la carga inicial, tipado de columnas y primer diagnóstico) y OpenRefine (para la limpieza profunda de texto y categorías) y la carga corresponde a la organización final de los datos en el modelo relacional propuesto.

Calidad de datos

Wang y Strong (1996) plantean que la calidad de los datos no se reduce a su exactitud, sino que incluye dimensiones como la completitud, la consistencia y la representación adecuada de la información para quien la consume. Bajo este marco, un valor en cero que en realidad representa un dato ausente, o una misma categoría escrita de dos formas distintas, constituyen problemas de calidad tan relevantes como un error numérico evidente, y justifican el trabajo de limpieza documentado en las secciones 5 y 6 de este documento.

Modelado relacional y normalización

El modelo relacional, propuesto originalmente por Codd (1970), organiza la información en relaciones (tablas) que representan entidades y sus atributos, evitando la redundancia mediante la normalización y garantizando la integridad de los datos a través de llaves primarias y foráneas. Elmasri y Navathe (2015) detallan que una tabla se normaliza identificando las dependencias funcionales reales entre sus atributos: cuando un atributo depende únicamente de otro (por ejemplo, un código de capítulo determina siempre el mismo nombre de capítulo), esa relación debe extraerse a una tabla independiente para evitar que el dato se repita en cada fila de la tabla original. Este es precisamente el criterio aplicado en el modelo relacional propuesto en la sección 7 de este documento.

Clasificaciones económicas colombianas

El dataset utiliza la Clasificación Industrial Internacional Uniforme de todas las actividades económicas, Revisión 4 adaptada para Colombia (CIIU Rev. 4 A.C.), publicada y mantenida por el Departamento Administrativo Nacional de Estadística (DANE, 2022), así como la Nomenclatura Arancelaria Común basada en el Sistema Armonizado para las partidas y capítulos arancelarios. Comprender estas clasificaciones es necesario para interpretar correctamente las jerarquías presentes en los datos (partida → capítulo, actividad CIIU) y para justificar las decisiones de modelado relacional tomadas.

Comercio exterior: FOB y CIF

Las estadísticas de comercio exterior en Colombia distinguen entre el valor FOB (Free On Board), que corresponde al valor de la mercancía puesta en el puerto de origen sin incluir flete ni seguro, y el valor CIF (Cost, Insurance, Freight), que suma a ese valor los costos de flete y seguro hasta el destino (Departamento Administrativo Nacional de Estadística [DANE], s.f.; Dirección de Impuestos y Aduanas Nacionales [DIAN], 2024). Esta relación conceptual (CIF ≥ FOB) es la que permitió detectar la inconsistencia lógica documentada en la sección 6 de este proyecto, donde se hallaron filas con valor FOB en cero pero valor CIF positivo.

Herramientas de limpieza de datos

Power Query es la herramienta de carga y transformación de datos integrada en Microsoft Excel, utilizada en este proyecto para la extracción inicial, el tipado de columnas y el primer diagnóstico de inconsistencias. OpenRefine, por su parte, es una herramienta de código abierto diseñada específicamente para trabajar con datos "sucios",

que ofrece funcionalidades de agrupamiento difuso (clustering), facetas, expresiones GREL y normalización de texto (OpenRefine, s.f.), utilizadas en este proyecto para la limpieza profunda de las categorías identificadas como inconsistentes.

CARACTERIZACIÓN Y ANÁLISIS DE LOS DATOS

Ficha técnica del dataset

- **Entidad responsable:** Secretaría Distrital de Desarrollo Económico (SDDE), a través del portal Datos Abiertos Bogotá.
- **Formato original:** Archivo de Excel (.xlsx), con una única hoja de datos útil (las demás hojas del libro se encuentran vacías).
- **Cantidad de registros y variables:** El archivo original descargado el 20 de agosto de 2026 contenía 132.280 registros y 17 columnas. Durante el proceso de documentación en OpenRefine se detectó que el archivo de trabajo consolidado contiene 264.586 filas; esta diferencia está siendo verificada contra una nueva descarga del dataset para confirmar si corresponde a una actualización posterior del portal Datos Abiertos Bogotá o a una carga duplicada en el proceso de extracción, y se reportará el resultado final de esta verificación antes de la entrega.
- **Periodo y cobertura:** Información acumulada mes a mes desde enero de 2025 hasta febrero de 2026, con cobertura de importaciones con destino a la ciudad de Bogotá.
- **Tipos de datos:** Columnas numéricas de periodo/mes, códigos que en el archivo original vienen tipados como enteros pero que conceptualmente son identificadores categóricos (código de país, de partida, de CIIU y de capítulo), columnas de texto descriptivo, y columnas numéricas decimales para las métricas de valor y peso.

Variables relevantes e identificadores:

Los identificadores naturales del dataset son el código de país de origen, el código de partida arancelaria, el código CIIU Rev. 4 A.C. y el código de capítulo; estos códigos, más que valores numéricos, funcionan como llaves de clasificación y así se tratan en el modelo relacional. Las variables de análisis (dólares CIF, dólares FOB, kilogramos netos y cantidad) son las que aportan valor cuantitativo a cada transacción de importación.

Valores vacíos, duplicados e inconsistencias:

No se encontraron celdas vacías (nulls) en ninguna columna del archivo original, pero sí se identificaron problemas equivalentes:

- **Duplicados exactos:** 9 filas completamente idénticas en todas sus columnas.
- **Valores faltantes disfrazados de cero:** 65 filas con dólares FOB en cero y 4 filas con kilogramos netos en cero, resultado atípico para una importación real.
- **Inconsistencias de formato:** El valor "Sin información" aparece escrito de dos formas distintas entre columnas ("Sin información" y "Sin Información"), generando dos categorías donde debería existir una sola.
- **Categorías CIIU inconsistentes:** 7 de 193 códigos CIIU presentaban más de una descripción asociada, principalmente por diferencias de puntuación o por la presencia del valor "Sin información" en lugar del texto real.
- **Redundancia estructural:** Cada fila repite en texto completo el nombre del país, la descripción de la partida y de la actividad CIIU, en lugar de almacenar solamente el código correspondiente.

Categorías y ambigüedad conceptual

La columna "País de origen" mezcla países reales con 23 registros que en realidad corresponden a Zonas Francas (por ejemplo, "Zona Franca Tayrona S.A."), que no son países sino un tipo de entidad distinto. Esta ambigüedad se resolvió en el modelo relacional mediante la creación de una tabla de tipo de origen (ver sección 7).

Patrones, tendencias y preguntas analizables

El dataset permite identificar, entre otros: (a) los países con mayor participación en el valor CIF total importado por Bogotá y su evolución mes a mes; (b) qué capítulos y partidas arancelarias concentran el mayor volumen de importaciones; (c) qué proporción de las importaciones corresponde a bienes de alto, medio o bajo nivel tecnológico; y (d) si existen meses o períodos con picos atípicos de importación para algún país o categoría en particular. La combinación de las variables de clasificación (país, partida, CIIU, nivel tecnológico, uso económico) con las métricas cuantitativas (FOB, CIF, kilogramos, cantidad) permite responder preguntas como: ¿qué países concentran las importaciones de mayor nivel tecnológico?, o ¿existe una relación entre el uso económico declarado y el valor promedio por transacción?

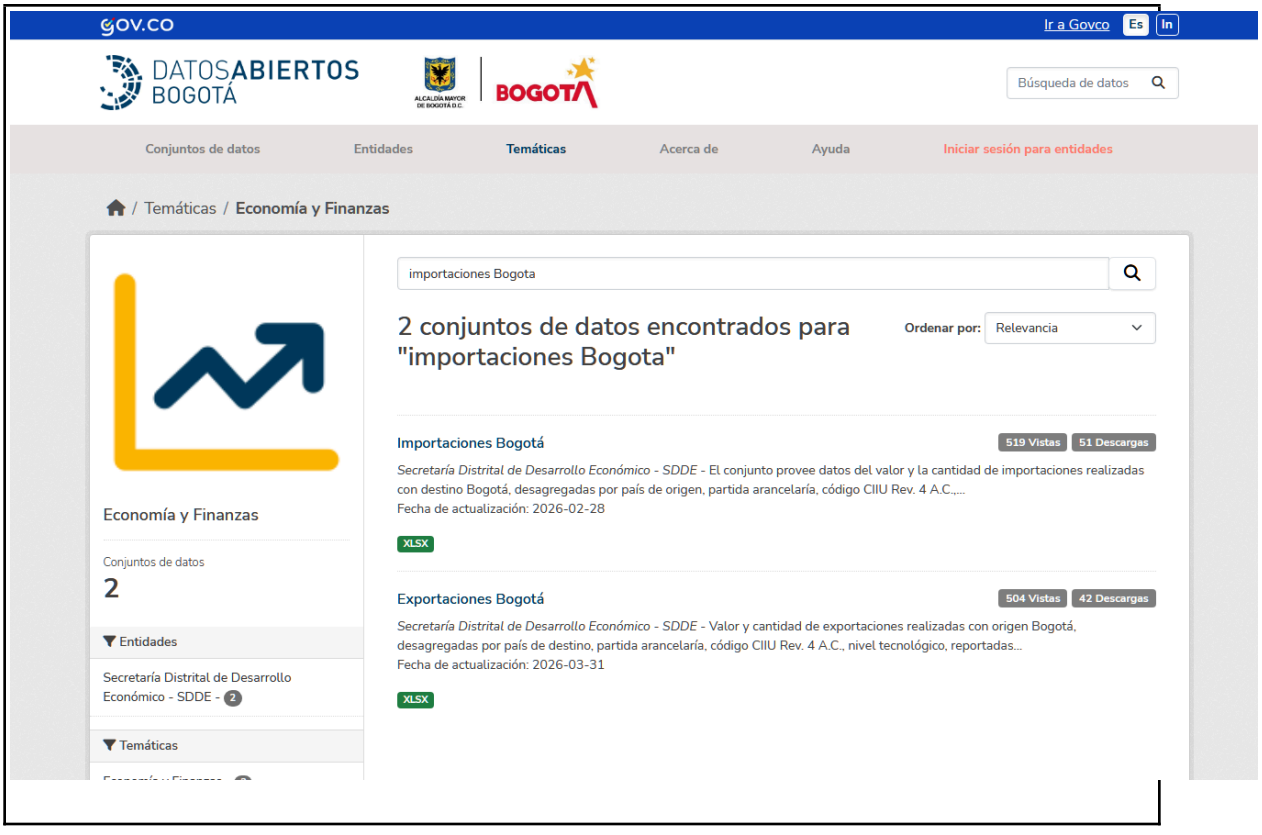
Problemas de calidad identificados

En síntesis, los problemas de calidad detectados fueron: redundancia de texto repetido, duplicados exactos, valores en cero potencialmente inválidos, inconsistencia de formato en campos categóricos y ambigüedad conceptual entre tipos de entidad distintos mezclados en una misma columna. Estos problemas son los que orientan directamente las transformaciones documentadas en la sección 6.

PROCESO ETL

Extracción

Los datos se localizaron y descargaron desde el portal Datos Abiertos Bogotá, en el conjunto de datos "Importaciones Bogotá" publicado por la Secretaría Distrital de Desarrollo Económico (https://datosabiertos.bogota.gov.co/dataset/importaciones-bogota), en formato Excel (.xlsx). Este dataset resulta apropiado para el problema planteado porque es la fuente oficial y de mayor granularidad disponible sobre las importaciones con destino a la ciudad, y porque su nivel de desagregación (país, partida, CIIU, nivel tecnológico) permite construir un modelo relacional con varias entidades relacionadas entre sí, en lugar de una tabla plana sin estructura interna.



Power Query

A continuación se documenta el proceso de carga y primer diagnóstico de los datos mediante Power Query de Excel.

Los datos se cargaron desde el archivo de Excel descargado de Datos Abiertos Bogotá: en la pestaña de Datos se seleccionó "Obtener datos" → "Desde un archivo" → "Desde un libro de Excel". Al importar, se seleccionó únicamente la Hoja 1, ya que las demás hojas del libro se encuentran vacías, y se confirmó que la primera fila contiene los encabezados de las columnas. El archivo no maneja delimitadores de texto plano (no es un .csv), sino que corresponde a un libro de Excel con distintos formatos de puntuación, comas y tildes en sus columnas de texto.

En total se identificaron 17 columnas, con los siguientes tipos de datos originales:

Columna	**Tipo de dato**
Periodo	Número
Mes	Número
Código país origen	Entero
País de origen	Texto
Código partida	Entero
Nombre partida	Texto
Código CIIU Rev4	Entero
Descripción CIIU Rev4	Texto
Código capítulo	Entero
Nombre capítulo	Texto
Nivel tecnológico	Texto
Uso económico	Texto
Detalle uso económico	Texto
Dólares CIF	Decimal
Dólares FOB	Decimal
Kilogramos netos	Decimal
Cantidad	Decimal

Se identificó que Power Query carga los códigos de país, partida, CIIU y capítulo como tipo entero, mientras que OpenRefine los interpreta como texto; dado que

conceptualmente son identificadores categóricos y no valores sobre los que tenga sentido operar aritméticamente, se corrigió su tipo de Entero a Texto directamente en Power Query, para mantener consistencia entre ambas herramientas.

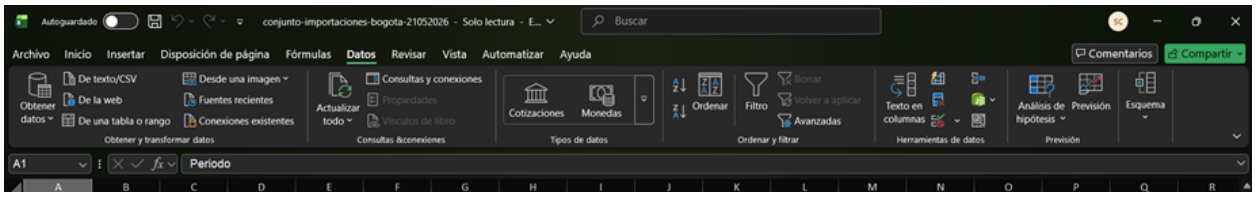
En cuanto a inconsistencias, se encontró un problema de lógica entre las columnas de valor: por definición, el valor CIF siempre debe ser mayor o igual al valor FOB, pues el primero se calcula sumando flete y seguro al segundo, y ninguno de los dos debería ser cero si la importación tuvo un valor comercial real. Filtrando la columna "Dólares FOB" por el valor 0, se identificaron 65 filas con FOB en cero pero con valor CIF positivo en esas mismas filas, lo que constituye una inconsistencia. Se decidió reemplazar esos ceros por valores nulos (clic derecho sobre la columna → Reemplazar valores → buscar 0, reemplazar por null), en lugar de estimar el FOB a partir del CIF (lo que introduciría un dato aproximado no verificado) o de eliminar esas filas (que siguen representando importaciones reales, aunque su proporción sea mínima).

Para identificar duplicados, se seleccionaron todas las columnas con Ctrl+clic sobre una consulta duplicada (para no alterar los datos originales) y, desde Inicio → Conservar filas → Conservar duplicados, se identificaron 9 filas completamente idénticas en todas sus columnas. Al tratarse de duplicados exactos que no aportan información adicional, se eliminaron sobre la consulta original mediante Inicio → Quitar filas → Quitar duplicados.

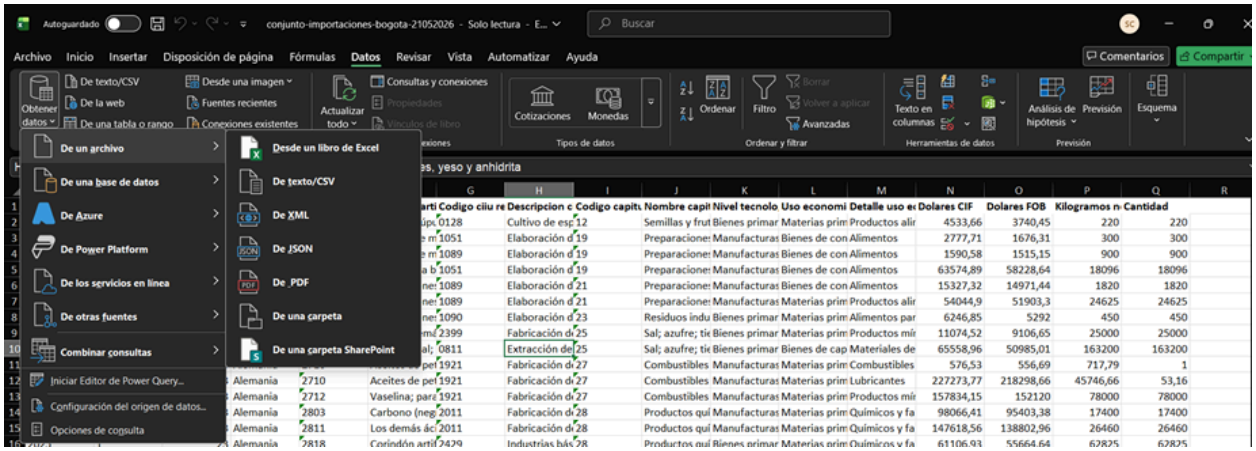
Para las categorías inconsistentes, se aisló la columna "Código CIIU Rev4" junto con su descripción en una consulta duplicada, se agrupó por código (Inicio → Agrupar por, operación "Contar filas distintas") y se filtró por conteo mayor a 1, encontrando 7 códigos con más de una descripción asociada. Para cada uno se aplicó el mismo criterio:

cuando la diferencia era únicamente de puntuación (por ejemplo, un punto final de más), se estandarizó hacia la forma sin punto; cuando una de las dos descripciones era el valor "Sin información" y el propio dataset contenía la descripción real para ese mismo código en otras filas, priorizamos la validez semántica sobre la frecuencia estadística y se completó el registro con la descripción real, en lugar de aplicar el criterio de mayoría. Por último, los valores "Sin información" remanentes en las columnas "Nivel tecnológico" (6.138 filas) y "Uso económico" (298 filas), para los cuales no fue posible inferir el valor real a partir de otras filas, se convirtieron a valores nulos, evitando que fueran tratados como una categoría válida en análisis posteriores.

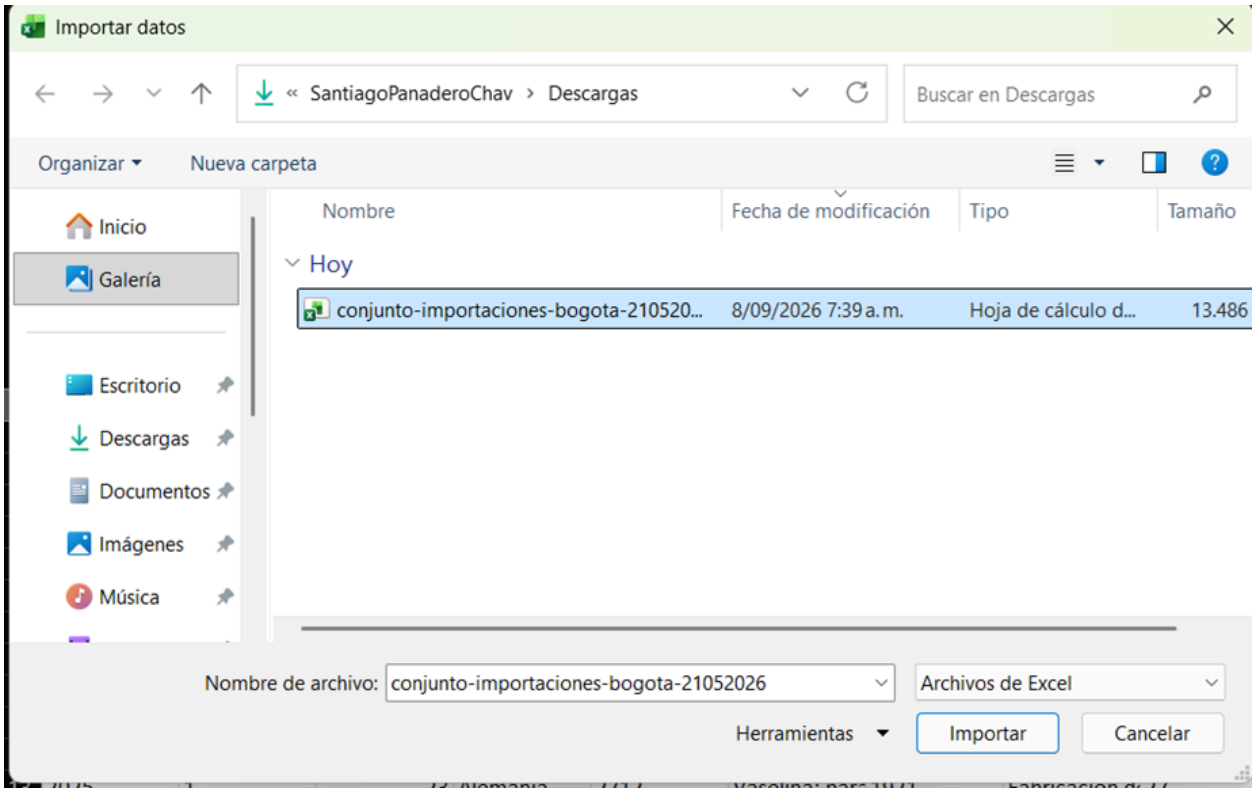
Proceso de desarrollo en Power Query



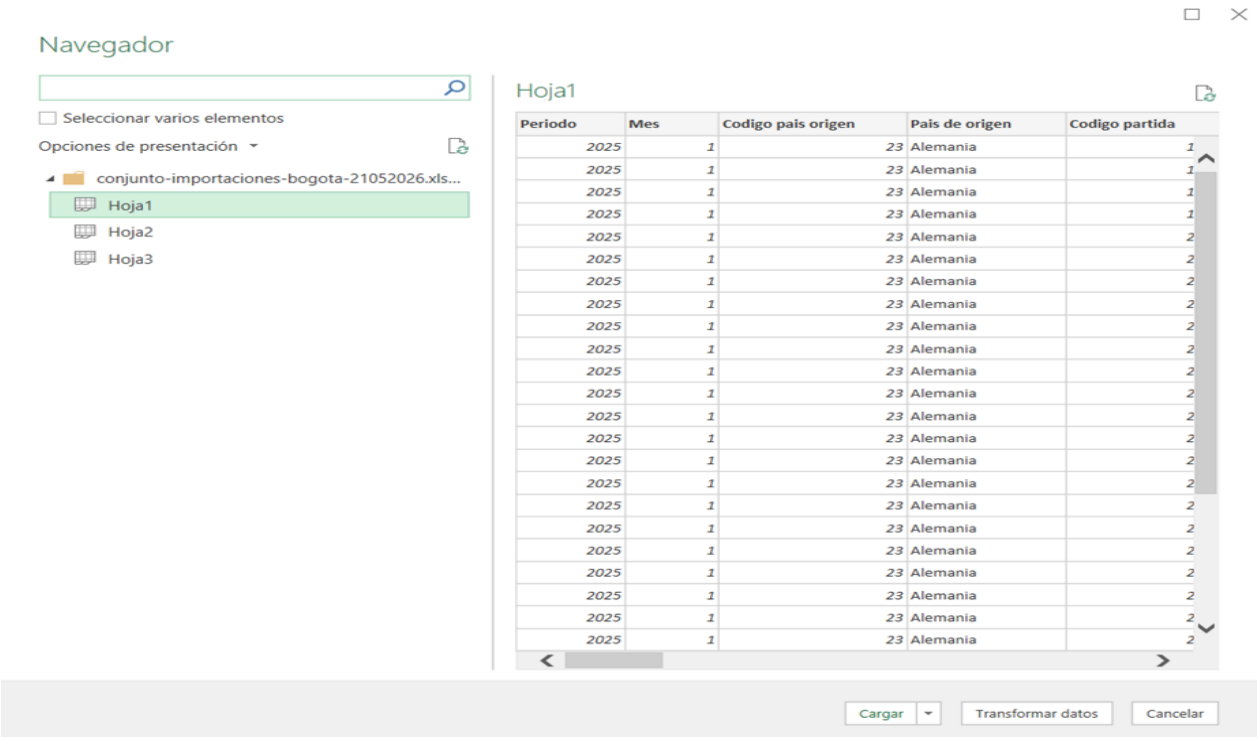
Los datos provienen de la web, de la página datos abiertos bogotá, el método para traer los datos de Excel a power query es primero entrar al aparato de datos y después entrar a Obtener Datos.



Luego se entra en el “Apartado de un archivo” y ahí le damos a “Desde un libro de Excel”

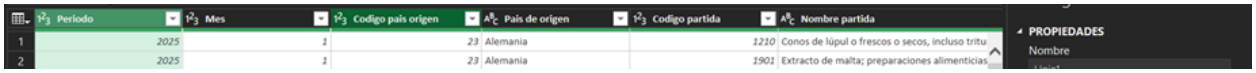


Seleccionamos el archivo y le damos importar



En esta imagen se selecciona solo la hoja 1, ya que las demás hojas se encuentran vacías.

Luego de seleccionarlo, le damos a Transformar Datos.



Como nos podemos dar cuenta, la primera fila son los nombres de las columnas

Nombre capitulo
Semillas y frutos oleaginosos, forrajes
Preparaciones a base de cereal, harina, leche; pastelería
Preparaciones a base de cereal, harina, leche; pastelería
Preparaciones a base de cereal, harina, leche; pastelería
Preparaciones alimenticias diversas
Preparaciones alimenticias diversas
Residuos industrias alimentarias. Alimentos para animales
Sal; azufre; tierras y piedras; yesos, cales y cementos
Sal; azufre; tierras y piedras; yesos, cales y cementos
Combustibles y aceites minerales y sus productos
Combustibles y aceites minerales y sus productos
Combustibles y aceites minerales y sus productos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos inorgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos
Productos químicos orgánicos

1.2 Dolares CIF	1.2 Dolares FOB	1.2 Kilogramos netos
4533,66	3740,45	220
2777,71	1676,31	300
1590,58	1515,15	900
63574,89	58228,64	18096
15327,32	14971,44	1820
54044,9	51903,3	24625
6246,85	5292	450
11074,52	9106,65	25000
65558,96	50985,01	163200
576,53	556,69	717,79
227273,77	218298,66	45746,66
157834,15	152120	78000
98066,41	95403,38	17400
147618,56	138802,96	26460
61106,93	55664,64	62825
234,73	217,3	40
10300	9778,72	2000
97340,27	91990,51	47180
40255,27	39240,42	7300
49451,3	46140,96	44000
56353,48	53004,16	14050
8923,38	7909	500
558,19	536,4	120
2194,39	2093,48	1160
30785,25	29755,24	15200
2257,45	2242,46	100
5618,47	5410,97	910
33131,58	32331,56	20360
134983,46	130176,95	61000
974,95	939,6	180
144088,95	140789,59	25490

Como se puede observar en las dos figuras anteriores, se observa que el archivo maneja toda clase de puntos, comas, tildes, etc. Además, el archivo no contiene tabulación, ya que es un archivo .xlsx por lo que no es un archivo de texto plano como un .csv o un .txt

Una nota importante es que el archivo cargado en power query contiene distintos tipos de datos, que cuando se cargan en open refine, ya que los datos integer los toma como text

Por ende, se optó por corregir primero los tipos de datos de las columnas con tipos de datos incorrectos:

Código país de origen: integer -> text

Codigo partida: integer -> text

Código ciiu rev4: integer -> text

Codigo capitulo: integer -> text

En total existen 17 columnas, con 132.289 registros en total

OpenRefine

A continuación se documenta el proceso de carga y primer diagnóstico de los datos mediante Power Query de Excel.

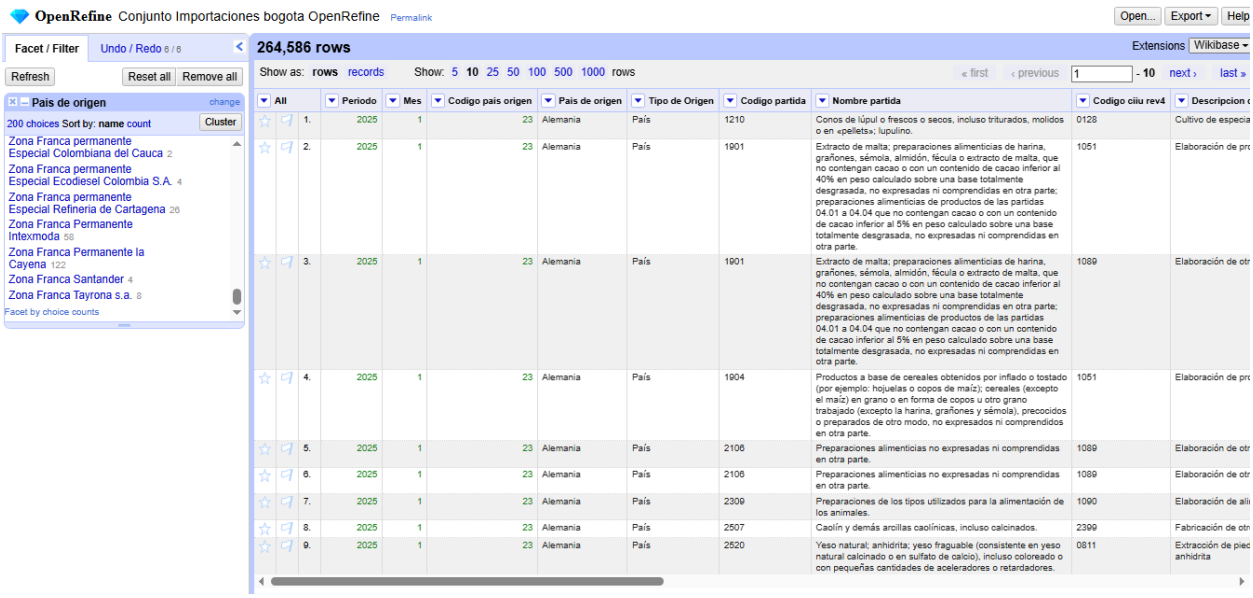
Normalización de texto y eliminación de espacios (columnas categóricas)

Problema:

Se requería verificar que las columnas categóricas del dataset (país, partida, CIIU, nivel tecnológico, uso económico) no contuvieran espacios extra ni inconsistencias de mayúsculas/minúsculas que pudieran generar duplicidad de categorías al momento del análisis.

Transformación:

Se revisó cada columna mediante Text facet para inspeccionar la totalidad de sus valores únicos. Se aplicó (o se habría aplicado, según el caso) Edit cells → Common transforms → Trim leading and trailing whitespace y Collapse consecutive whitespace sobre las columnas donde se detectaran anomalías.



Justificación:

Verificar el estado textual de estas columnas es indispensable antes de cualquier análisis agregado, ya que un mismo valor real escrito de dos formas distintas se contaría como dos categorías diferentes, distorsionando conteos y agrupaciones.

Resultado:

Al revisar los facets de las columnas categóricas principales, se confirmó que la mayoría llegaban ya consistentes en texto (sin espacios ni variaciones de mayúsculas), a excepción de la columna "Nivel tecnológico", que presentó un problema distinto: una cantidad considerable de valores vacíos (ver punto de tratamiento de nulos).

Tratamiento de valores nulos

Problema:

Se detectaron valores vacíos (*blank*) en dos columnas de naturaleza distinta: "Nivel tecnológico" (2.129 registros, tras confirmar el conteo real del dataset completo) y "Dólares FOB" (50 registros).

Transformación:

- Para Nivel tecnológico, al observarse que la columna ya contaba con una categoría existente llamada "Sin información" (10.148 registros), se unificaron los blanks bajo esa misma etiqueta mediante Edit cells → Transform:

if(isBlank(value), "Sin información", value)

- Para Dólares FOB, al tratarse de una columna numérica, se optó por rellenar los vacíos con 0 mediante:

if(isBlank(value), 0, value)



Nivel tecnológico antes del tratamiento de los blanks



Nivel tecnológico después del tratamiento de los blanks



Dólares FOB antes del tratamiento de los blanks



Dólares FOB despues del tratamiento de los blanks (unificado con 0)

Justificación:

El tratamiento debe ajustarse a la naturaleza del dato: en una columna categórica, un vacío puede representar legítimamente "no se pudo clasificar"; en una numérica que se usará en sumatorias, 0 es el valor operacionalmente correcto. Adicionalmente, se identificó que un facet/filtro activo puede ocultar registros al momento de aplicar una transformación, por lo que se verificó el conteo final con todos los filtros reseteados para asegurar cobertura total sobre el dataset.

Resultado:

"Nivel tecnológico" quedó unificado en "Sin información: 12.277" registros, sin blanks. "Dólares FOB" quedó en 0 blanks, con los 50 registros afectados en valor 0.

Revisión final de duplicados

Problema:

Antes de dar por cerrada la depuración, era necesario confirmar que la consulta ya limpia no contuviera filas duplicadas que pudieran inflar artificialmente los totales de importaciones.

Transformación:

Se creó una columna auxiliar ("Clave_duplicados") concatenando mediante GREL las columnas que identifican una transacción (país de origen, partida, CIIU, periodo y mes), y se exploró dicha columna con Text facet, ordenando por conteo (*Sort by: count*) para detectar valores repetidos. Adicionalmente, se realizó una verificación cruzada comparando la totalidad de las columnas (no solo la clave compuesta) para descartar coincidencias parciales.



Justificación:

Un conteo alto en la clave compuesta no implica automáticamente un duplicado: era necesario verificar los valores numéricos de cada fila dentro de un mismo grupo para confirmar si representaban la misma transacción repetida o transacciones distintas que simplemente comparten país, partida, CIIU y periodo. Sin embargo, la verificación de fila completa sí permite identificar con certeza los casos en que absolutamente todos los valores (incluyendo dólares CIF, FOB, kilogramos netos y cantidad) coinciden, lo cual constituye evidencia sólida de un duplicado real y no de dos transacciones distintas.

Resultado:

La mayoría de los grupos con mayor conteo en la clave compuesta correspondían a transacciones distintas y legítimas, cada una con valores propios de Dólares FOB, CIF, kilogramos netos y cantidad. No obstante, se identificaron 17 filas que sí eran duplicados exactos (idénticas en la totalidad de sus 21 columnas), las cuales fueron eliminadas de la consulta mediante Inicio → Quitar filas → Quitar duplicados, considerando todas las columnas. La columna auxiliar "Clave_duplicados" fue eliminada tras completar la verificación.

Corrección de tipos de datos remanentes

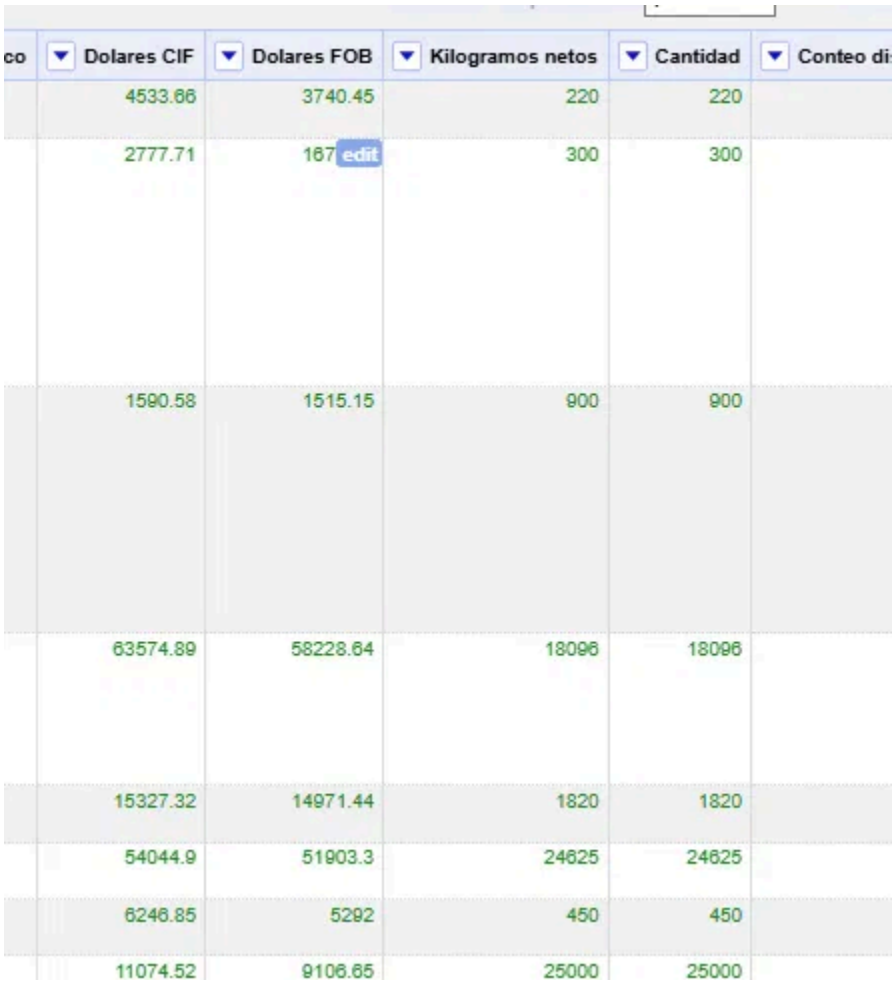
Problema:

Aunque en Power Query ya se habían corregido los tipos de las columnas de código (código país de origen, código partida, código CIIU rev4, código capítulo, de integer a text), era necesario verificar en OpenRefine si las columnas numéricas restantes (Dólares

CIF, Dólares FOB, Kilogramos netos, Cantidad) habían quedado correctamente tipadas como números tras la importación.

Transformación:

Se inspeccionó visualmente cada columna en OpenRefine, donde los valores numéricos se muestran alineados a la derecha y en color verde cuando son reconocidos como tipo numérico.



co	Dolares CIF	Dolares FOB	Kilogramos netos	Cantidad	Conteo di
	4533.66	3740.45	220	220	
	2777.71	167 edit	300	300	
	1590.58	1515.15	900	900	
	63574.89	58228.64	18096	18096	
	15327.32	14971.44	1820	1820	
	54044.9	51903.3	24625	24625	
	6246.85	5292	450	450	
	11074.52	9106.65	25000	25000	

Justificación:

Confirmar el tipo de dato correcto es necesario para garantizar que las operaciones

matemáticas (sumas, promedios, agregaciones por categoría) se ejecuten correctamente en las etapas posteriores del análisis.

Resultado:

Las cuatro columnas numéricas revisadas (Dólares CIF, Dólares FOB, Kilogramos netos, Cantidad) se confirmaron correctamente tipadas como números, sin necesidad de conversión adicional en OpenRefine.

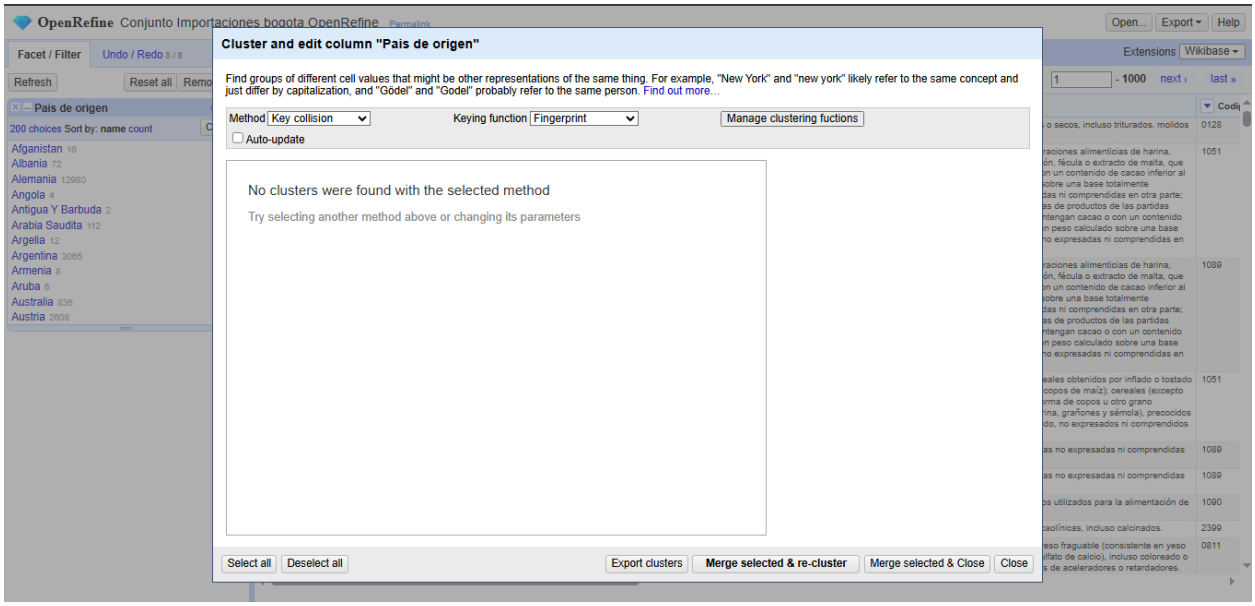
Clustering (verificación de variantes de escritura)

Problema:

Se buscó determinar si las columnas de texto libre (como "País de origen") presentaban variantes de escritura no evidentes a simple vista (errores tipográficos, mayúsculas/minúsculas inconsistentes, abreviaturas).

Transformación:

Se aplicó la herramienta Cluster (facet por texto) sobre las principales columnas categóricas, probando el método key collision con fingerprint.



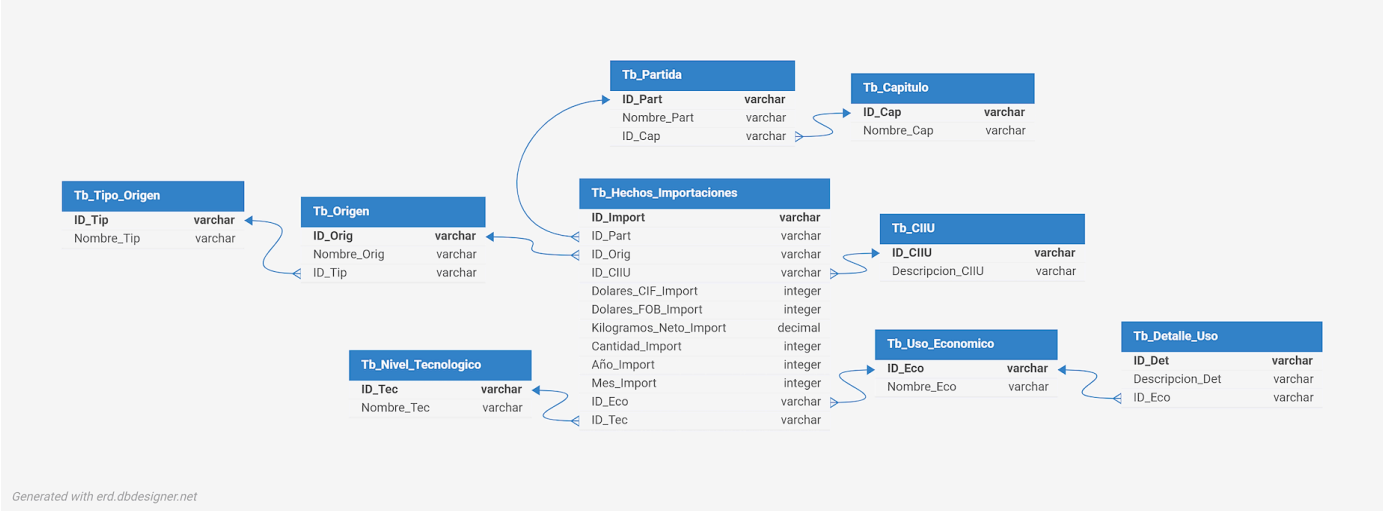
Justificación:

El clustering es un paso de verificación obligatorio dentro del flujo de limpieza, incluso cuando no se detectan problemas, ya que confirma la calidad de los datos de origen y descarta errores silenciosos.

Resultado:

No se encontraron variantes ni agrupaciones sugeridas por la herramienta en las columnas revisadas (por ejemplo, "País de origen" no arrojó clusters), lo que indica que esas columnas ya llegaban con un nivel de consistencia textual adecuado, sin necesidad de fusionar valores.

MODELO RELACIONAL



A partir del análisis de consistencia realizado sobre los datos (sección 5), se identificaron las siguientes entidades, atributos y relaciones:

- País/Origen (código, nombre), junto con un Tipo de Origen (país o zona franca) que resuelve la ambigüedad detectada en la columna original.
- Partida arancelaria (código, nombre, capítulo al que pertenece).
- Capítulo (código, nombre).
- Actividad CIIU (código, descripción).
- Clasificación económica: nivel tecnológico, uso económico y detalle de uso económico.
- Importación (tabla de hechos): relaciona período, mes, país, partida, CIIU y clasificación económica, con las métricas de dólares CIF, dólares FOB, kilogramos netos y cantidad.

La relación central del modelo es: cada importación ocurre en un período/mes, proviene de un origen (país o zona franca), corresponde a una partida arancelaria (que

pertenece a un capítulo), y esa partida se asocia además a una actividad CIIU y a una clasificación económica propia de la transacción.

Figura 1. Modelo relacional propuesto para el dataset de importaciones con destino a Bogotá.

Justificación de las tablas propuestas

Tb_Origen (antes "Tb_Pais") + Tb_Tipo_Origen:

La columna original "País de origen" no representaba únicamente países, sino también Zonas Francas; nombrar la tabla Tb_Pais sería conceptualmente incorrecto, pues no todas sus filas son países. Se generalizó el nombre a Tb_Origen y se creó un catálogo Tb_Tipo_Origen (con únicamente los valores "País" y "Zona Franca"), referenciado desde Tb_Origen mediante la llave foránea ID_Tip. Esto permite filtrar explícitamente "solo países reales" o "solo zonas francas" sin depender de interpretar el texto del nombre.

Tb_Capitulo:

Se comprobó que "código de capítulo → nombre de capítulo" es una dependencia funcional estricta (cada código tiene siempre el mismo nombre en las 132.289 filas), lo que justifica extraerla a su propia tabla y dejar de repetir el nombre en cada fila.

Tb_Partida:

De forma análoga, "código de partida → nombre de partida" y "código de partida → código de capítulo" son también relaciones 1 a 1 estrictas, confirmando una jerarquía real de clasificación aduanera. La llave foránea ID_Cap se ubica en Tb_Partida (el lado

"muchos" de la relación), y no en Tb_Capitulo, porque un capítulo agrupa muchas partidas, pero cada partida pertenece a un único capítulo.

Tb_CIIU:

La relación "código CIIU → descripción" es mayoritariamente 1 a 1 (solo 7 de 193 códigos presentaban inconsistencia), lo que justifica su extracción como catálogo independiente. Se comprobó además que la relación entre partida y CIIU es de muchos a muchos (154 de 1.139 partidas tienen más de un CIIU asociado, y un mismo CIIU aplica a varias partidas); en lugar de crear una tabla puente adicional, esta relación N:M queda resuelta porque Tb_Hechos_Importaciones ya almacena ambas llaves foráneas (ID_Part e ID_CIIU) en la misma fila, registrando la combinación específica que realmente ocurrió.

Tb_Nivel_Tecnologico, Tb_Uso_Economico, Tb_Detalle_Uso:

Se crearon como catálogos por tratarse de campos de texto con pocos valores posibles y fijos (7 niveles tecnológicos, 4 usos económicos, 34 detalles), y porque ya se había detectado inconsistencia de escritura en ellos. Se comprobó empíricamente que ni el nivel tecnológico ni el uso económico dependen de forma única de la partida, el capítulo o el CIIU (por ejemplo, 92 de 1.139 partidas registran más de un nivel tecnológico), por lo que su llave foránea se ubica directamente en Tb_Hechos_Importaciones: son clasificaciones de la transacción, no una propiedad fija del producto. Tb_Detalle_Uso, en cambio, sí presenta una dependencia 1 a 1 real con Tb_Uso_Economico (0 excepciones encontradas), por lo que lleva su propia llave foránea ID_Eco hacia esa tabla.

Tb_Hechos_Importaciones:

Es la tabla de hechos que representa cada evento real de importación. Contiene únicamente las llaves foráneas hacia los catálogos y las métricas propias de cada transacción (dólares CIF, dólares FOB, kilogramos netos, cantidad, año y mes), sin llave directa hacia Tb_Capitulo, pues ese dato ya es alcanzable navegando Hechos → Partida → Capítulo, evitando así una redundancia que podría generar inconsistencias.

Principio de dirección de las llaves foráneas

En todo el modelo se aplicó de forma consistente el mismo principio: la llave foránea se coloca siempre en la tabla del lado "muchos" de la relación, apuntando hacia la tabla del lado "uno", porque es la única dirección que garantiza que la relación sea navegable sin ambigüedad (por ejemplo, Partida → Capítulo es correcto, mientras que Capítulo → Partida no tendría una respuesta única).

Cómo el modelo garantiza consistencia e integridad

El modelo garantiza consistencia e integridad mediante: una fuente única de verdad para cada dato descriptivo (corregir un error de escritura implica corregirlo una sola vez en el catálogo, y no en miles de filas repetidas); integridad referencial (cada llave foránea de Tb_Hechos_Importaciones sólo puede apuntar a un valor existente en su catálogo correspondiente); eliminación de duplicados reales sobre la llave de cada catálogo; consistencia de formato en campos antes propensos a inconsistencia de escritura; coherencia de tipos de datos entre cada llave foránea y su llave primaria; y una separación clara entre los atributos que son propiedad fija de un producto y los que varían

por transacción, evitando forzar relaciones 1 a 1 donde los datos reales muestran que son de muchos a muchos.

ANÁLISIS DESPUÉS DEL ETL

Problemas encontrados y corregidos

Antes del proceso ETL, el dataset presentaba: 9 filas duplicadas exactas, 65 filas con valor FOB en cero (inconsistentes frente a un valor CIF positivo), 4 filas con kilogramos netos en cero, inconsistencias de escritura en 7 códigos CIIU y en los valores "Sin información" de nivel tecnológico y uso económico, y una ambigüedad conceptual entre países y zonas francas en la columna de origen. Tras el trabajo realizado en Power Query se corrigieron los duplicados exactos, se marcaron como nulos los valores en cero identificados como faltantes disfrazados, y se estandarizaron las 7 categorías CIIU inconsistentes. Adicionalmente, en una revisión final de consistencia sobre la totalidad de las columnas (no solo sobre la clave compuesta de identificación de transacción), se identificaron y eliminaron 17 filas adicionales con duplicación exacta total, que no habían sido detectadas en la revisión inicial por clave compuesta debido a que esta solo consideraba país, partida, CIIU, periodo y mes, sin verificar las columnas de valor.

Problemas que permanecen / pendientes de OpenRefine

Tras finalizar el trabajo en OpenRefine, se confirmó lo siguiente: el clustering (key collision con fingerprint) no detectó variantes de escritura adicionales en las columnas categóricas revisadas, lo que indica que esas columnas ya llegaban con un nivel de consistencia textual adecuado. La separación entre países y zonas francas sí se materializó como una columna independiente ("Tipo de Origen"), resolviendo la ambigüedad conceptual detectada en la columna original "País de origen". No se identificaron inconsistencias adicionales en las demás columnas de texto libre revisadas.

El único punto que permanece abierto es la verificación final del conteo total de registros del archivo consolidado, para confirmar que corresponde exactamente al dataset original descargado de Datos Abiertos Bogotá.

Mejoras obtenidas y utilidad para responder al problema

Con las correcciones aplicadas, el dataset permite ahora responder con mayor confianza preguntas como la participación de cada país o categoría CIIU en el valor total importado, sin el riesgo de que un duplicado exacto o un valor cero malinterpretado distorsione los resultados. La estructuración en un modelo relacional adicionalmente permite consultar la información sin arrastrar el texto repetido del archivo original, mejorando tanto el rendimiento como la mantenibilidad de cualquier análisis posterior.

RESULTADOS Y CONCLUSIONES

Resultados principales

El proyecto permitió:

(a) confirmar, mediante el análisis de dependencias funcionales, que los datos de importaciones con destino a Bogotá tienen una estructura jerárquica real (país/origen, partida/capítulo, CIIU) que justifica un modelo relacional de varias tablas y no una tabla plana única.

(b) identificar y corregir problemas de calidad concretos que habrían distorsionado cualquier análisis realizado directamente sobre el archivo original.

(c) diseñar un modelo relacional de nueve tablas que resuelve explícitamente la ambigüedad entre países y zonas francas y la relación muchos a muchos entre partidas y actividades CIIU.

Conclusiones

- **Hallazgos principales:** el archivo de Datos Abiertos Bogotá, pese a estar completo en apariencia (sin celdas vacías), escondía problemas de calidad equivalentes a datos faltantes (ceros disfrazados) y a duplicados exactos, además de mezclar dos tipos de entidad distintos en una misma columna.
- **Utilidad de los datos:** una vez depurados y modelados, los datos permiten caracterizar de forma confiable el comercio de importación de la ciudad por país, sector económico y nivel tecnológico.
- **Aporte del proceso ETL:** sin las etapas de extracción, limpieza y transformación documentadas en la sección 6, cualquier análisis realizado sobre el archivo original habría heredado sus inconsistencias.

- Utilidad del modelo relacional: el modelo propuesto centraliza cada dato descriptivo en un único lugar, de modo que una corrección futura (por ejemplo, un cambio en la descripción oficial de un código CIIU) se aplica una sola vez y no en miles de filas.
- Limitaciones: el análisis se restringe al período cubierto por el dataset (enero 2025-febrero 2026) y a las columnas disponibles en el archivo original; algunas decisiones de limpieza (por ejemplo, tratar los ceros de FOB como nulos en lugar de estimarlos) son razonables pero no las únicas posibles.
- Trabajos futuros: implementar físicamente el modelo relacional en un motor de base de datos, cruzar este dataset con el de "Exportaciones Bogotá" del mismo portal para un análisis de balanza comercial distrital, y automatizar el proceso ETL para que se ejecute cada vez que la Secretaría Distrital de Desarrollo Económico publiqué una nueva actualización del dataset.

REFERENCIAS

- Codd, E. F. (1970). A relational model of data for large shared data banks. *Communications of the ACM, 13*(6), 377-387. https://doi.org/10.1145/362384.362685
- Congreso de la República de Colombia. (2014). Ley 1712 de 2014, por medio de la cual se crea la Ley de Transparencia y del Derecho de Acceso a la Información Pública Nacional y se dictan otras disposiciones. https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=56882
- Departamento Administrativo Nacional de Estadística [DANE]. (2022). Clasificación Industrial Internacional Uniforme de todas las actividades económicas, Revisión 4 adaptada para Colombia - CIIU Rev. 4 A.C. (2022). https://www.dane.gov.co/files/sen/nomenclatura/ciiu/CIIU_Rev_4_AC2022.pdf
- Departamento Administrativo Nacional de Estadística [DANE]. (s.f.). Ficha metodológica: Estadísticas de Importaciones. https://www.dane.gov.co/files/investigaciones/fichas/ficha_importaciones.pdf
- Dirección de Impuestos y Aduanas Nacionales [DIAN]. (2024). Bases estadísticas de comercio exterior - Importaciones (IN-IIT-0292). https://www.dian.gov.co/atencionciudadano/LMDP/Informacion-Innovacion-y-Tecnologia/Gobernanza-de-Datos-Analitica-y-Estudios-Economicos/Instructivos/IN-IIT-0292.pdf
- Elmasri, R., & Navathe, S. B. (2015). Fundamentals of Database Systems (7.ª ed.). Addison-Wesley.

- Kimball, R., & Caserta, J. (2004). The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data. Wiley.
- OpenRefine. (s.f.). OpenRefine: a free, open source power tool for working with messy data and improving it. GitHub. https://github.com/OpenRefine/OpenRefine
- Secretaría Distrital de Desarrollo Económico. (2026). Importaciones Bogotá. Datos Abiertos Bogotá. Recuperado el 20 de agosto de 2026. https://datosabiertos.bogota.gov.co/dataset/importaciones-bogota
- Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. Journal of Management Information Systems, 12(4), 5-33. https://doi.org/10.1080/07421222.1996.11518099
- **Aclaración:** Cabe aclarar que el uso de la Inteligencia Artificial, específicamente Claude A.I. que se hizo bastante presente durante la realización de este documento, principalmente para la redacción y retroalimentación de los procesos desarrollados para este proyecto.