# Nota técnica: integración de datos públicos

Bogotá DataJam 2026 · Equipo S3D.ETL (UCompensar) · Proyecto: dependencia y concentración de las importaciones de Bogotá

| Fuente | Entidad | Llave de integración | Cobertura lograda |
|---|---|---|---|
| Importaciones Bogotá (132.289 registros) | SDDE, Portal Datos Abiertos Bogotá | Tabla de hechos | 132.280 registros tras la limpieza |
| TRM diaria | Superintendencia Financiera (datos.gov.co, API Socrata) | Año + mes (TRM promedio mensual) | 100 % de los registros |
| ISO 3166 + regiones ONU M49 (y tabla puente de nombres en español) | ONU / ISO (repositorios públicos) | País → código ISO alfa-3 | 96,5 % del CIF automático, 1,1 % manual, 1,75 % zonas francas, 0,6 % sin identificar |

## 1. Dificultades de acceso, calidad, actualización y documentación

- **Cobertura distinta a la declarada:** la ficha indica datos de enero de 2025 a febrero de 2026, pero el archivo solo trae enero y febrero de cada año. Esto impide construir series mensuales y obliga a comparar bimestres.
- **Calidad:** 9 filas duplicadas exactas; 65 valores FOB y 4 pesos en cero que en realidad son datos faltantes; 7 códigos CIIU con más de una descripción; «Sin información» y «Sin Información» usados como categorías (6.137 registros en nivel tecnológico y 298 en uso económico); códigos numéricos que pierden ceros a la izquierda.
- **Documentación:** no hay diccionario de datos que explique las clasificaciones de nivel tecnológico y uso económico, ni la diferencia entre país de origen y zona franca.

## 2. Retos en la integración de fuentes

El principal reto fue que **no existe una llave común**. La columna de país usa nombres en español con variantes («Tunicia», «Belarus», «Swasilandia»), nombres truncados («Vírgenes Islas (Estados Unido») y 23 zonas francas colombianas mezcladas con países, y el código de país de la fuente no corresponde al estándar ISO. Lo resolvimos con normalización de texto (minúsculas y sin tildes), una tabla puente de nombres ISO en español y una tabla de equivalencias manual de 26 casos, documentada en el repositorio. Para la TRM fue necesario agregar la serie diaria a promedios mensuales, para que coincidiera con la granularidad de las importaciones.

## 3. Limitaciones

- Solo se compara el primer bimestre de dos años, así que no es posible analizar estacionalidad ni tendencia de largo plazo.
- El código «Otros» de la fuente agrupa 10 orígenes no identificables (0,6 % del CIF). La conversión a pesos usa la TRM promedio del mes y no la fecha exacta de cada declaración.
- Sin datos de exportaciones en el mismo formato no se puede calcular la balanza comercial por socio.

## 4. Recomendaciones para mejorar el uso de datos públicos

- Publicar el país de origen con código ISO 3166 y separar las zonas francas en una columna propia.
- Publicar la serie mensual completa, con un diccionario de datos e historial de versiones, y corregir la descripción de cobertura temporal.
- Usar valores nulos en lugar de ceros o del texto «Sin información» cuando falte un dato.
- Publicar exportaciones con la misma estructura para habilitar análisis de balanza comercial.

## 5. Utilidad de los datos para comprender el problema

Una vez integradas, las fuentes permitieron cuantificar la dependencia de Bogotá. China y Estados Unidos concentran el 52 % del valor importado, el IHH por país subió de 1.505 a 1.556, y Asia superó a América como primera región de origen en 2026 (43,4 % frente a 40,1 %). La integración con la TRM reveló algo que una sola fuente no muestra: el valor importado creció 8,8 % en dólares pero cayó 4,8 % en pesos, por la apreciación del peso (TRM −12,5 %). Esta lectura combinada es útil para que la SDDE priorice la diversificación de proveedores y siga el costo real de los insumos importados para las empresas de la ciudad.